# Analisis Perbandingan Algoritma NLP dalam Mengklasifikasikan Kategori Produk Berdasarkan Ulasan Pelanggan Tokopedia


**Disusun oleh:**

| | |
|---|---|
| Yurida Yahsya | (0110224100) |
| Ayu Nur Intany | (0110224133) |
| Dania Islamia | (0110224221) |
| Nuril Anwar Al-Absory | (0110224128) |

**SEKOLAH TINGGI TEKNOLOGI TERPADU NURUL FIKRI**

**PROGRAM STUDI TEKNIK INFORMATIKA**

**DEPOK**


**2026**

# DAFTAR ISI

**DAFTAR ISI** ..... **2**

**DAFTAR GAMBAR** ..... **4**

**BAB I PROBLEM DEFINITION** ..... **5**

1.1. Latar Belakang ..... 5

1.2. Identifikasi Masalah ..... 5

1.3. Rumusan Masalah ..... 5

1.4. Tujuan ..... 5

**BAB II DATASET** ..... **6**

2.1. Deskripsi Dataset ..... 6

2.2. Pengambilan Sampel (Data Sampling) ..... 6

2.3. Struktur Data ..... 7

2.4. Integrasi Fitur (Feature Combination) ..... 8

**BAB III PREPROCESSING** ..... **9**

3.1. Tahapan Pembersihan Data ..... 9

3.2. Hasil Akhir Data Preprocessing ..... 10

**BAB IV FEATURE EXTRACTION** ..... **11**

4.1. TF-IDF (Term Frequency - Inverse Document Frequency) ..... 11

4.2. Word Embedding (Word2Vec) ..... 11

4.3. Perbandingan Karakteristik Fitur ..... 12

**BAB V MODELING** ..... **13**

5.1. Algoritma Klasifikasi ..... 13

5.2. Hasil Eksperimen dan Perbandingan Akurasi ..... 13

5.3. Analisis Hasil Performa ..... 13

5.4. Evaluasi Mendalam (Classification Report) ..... 14

5.5. Penyimpanan Model untuk Deployment ..... 14

**BAB VI EXPERIMENT & COMPARISON ..... 16**

6.1. Analisis Performa Model Berdasarkan Fitur ..... 16

6.2. Analisis Confusion Matrix ..... 16

6.3. Hasil Prediksi Real-Time (Aplikasi) ..... 17

6.4. Kecepatan Komputasi ..... 18

**BAB VII INSIGHT ..... 19**

**BAB VIII CONCLUSION ..... 20**

8.1. Kesimpulan ..... 20

8.2. Saran ..... 20

# DAFTAR GAMBAR

Gambar 1. Distribusi Frekuensi Kategori pada Dataset Mentah (Original Dataset dengan 65.000 Data) ..... 6
Gambar 2. Distribusi Kategori Produk Setelah Balanced Sampling (Total 12.000 Data) ..... 7
Gambar 3. Tampilan Dataset setelah tahap Balancing (Raw Data). ..... 8
Gambar 4. Tabel Hasil Akhir Preprocessing ..... 10
Gambar 5. Proses Transformasi TF-IDF dengan N-Gram (1, 2) dan limitasi 5.000 fitur ..... 11
Gambar 6. Proses Training Word2Vec dan Tahap Vector Averaging untuk mendapatkan representasi kalimat. ..... 12
Gambar 7. Matriks evaluasi (Precision, Recall, F1-Score) per kategori produk. ..... 14
Gambar 8. Proses ekspor model SVM dan TF-IDF Vectorizer ke dalam format file .pkl ..... 15
Gambar 9. Confusion Matrix dari model terbaik SVM + TF-IDF. ..... 16
Gambar 10. Uji coba prediksi ulasan produk menggunakan aplikasi Gradio. ..... 17

# BAB I
# PROBLEM DEFINITION

## 1.1. Latar Belakang

Dalam ekosistem e-commerce seperti Tokopedia, volume ulasan produk bertumbuh secara eksponensial setiap harinya. Ulasan pelanggan bukan hanya sekadar testimoni, melainkan sumber data penting yang merepresentasikan identitas sebuah produk. Namun, seringkali terjadi inkonsistensi dalam penempatan kategori produk atau sulitnya melakukan pemetaan kategori secara manual jika hanya mengandalkan ribuan teks ulasan yang tidak terstruktur.

## 1.2. Identifikasi Masalah

Teks ulasan dari pelanggan memiliki karakteristik yang sulit diproses langsung oleh mesin karena:

- **Noise:** Adanya penggunaan angka, tanda baca, emoji, dan karakter spesial yang tidak relevan dengan kategori produk.
- **Ambiguitas Bahasa:** Penggunaan kata berimbuhan (misal: "memakan", "makanan") yang dianggap sebagai kata yang berbeda oleh mesin, padahal memiliki akar kata yang sama.
- **Stopwords:** Banyaknya kata umum (seperti "yang", "dan", "di") yang tidak memberikan informasi bermakna mengenai kategori produk.

## 1.3. Rumusan Masalah

Bagaimana cara membangun model Natural Language Processing (NLP) yang mampu mengklasifikasikan kategori produk secara otomatis dan akurat berdasarkan teks ulasan pelanggan yang telah melalui proses pembersihan (preprocessing)?

## 1.4. Tujuan

- Melakukan standarisasi teks ulasan melalui tahap preprocessing (Case folding, Cleansing, Stopword Removal, dan Stemming).
- Membandingkan performa berbagai algoritma Machine Learning (Naive Bayes, Logistic Regression, dan SVM) untuk menemukan model terbaik dalam memprediksi kategori produk.
- Mengembangkan antarmuka sederhana menggunakan Gradio untuk mendemonstrasikan hasil prediksi kategori secara real time.

# BAB II
# DATASET

## 2.1. Deskripsi Dataset

Dataset yang digunakan dalam proyek ini bersumber dari data publik ulasan produk marketplace Tokopedia tahun 2025 yang tersedia di platform Kaggle. Dataset mentah awalnya terdiri dari puluhan ribu baris data yang mencakup informasi nama produk, teks ulasan pelanggan, rating, dan kategori produk.

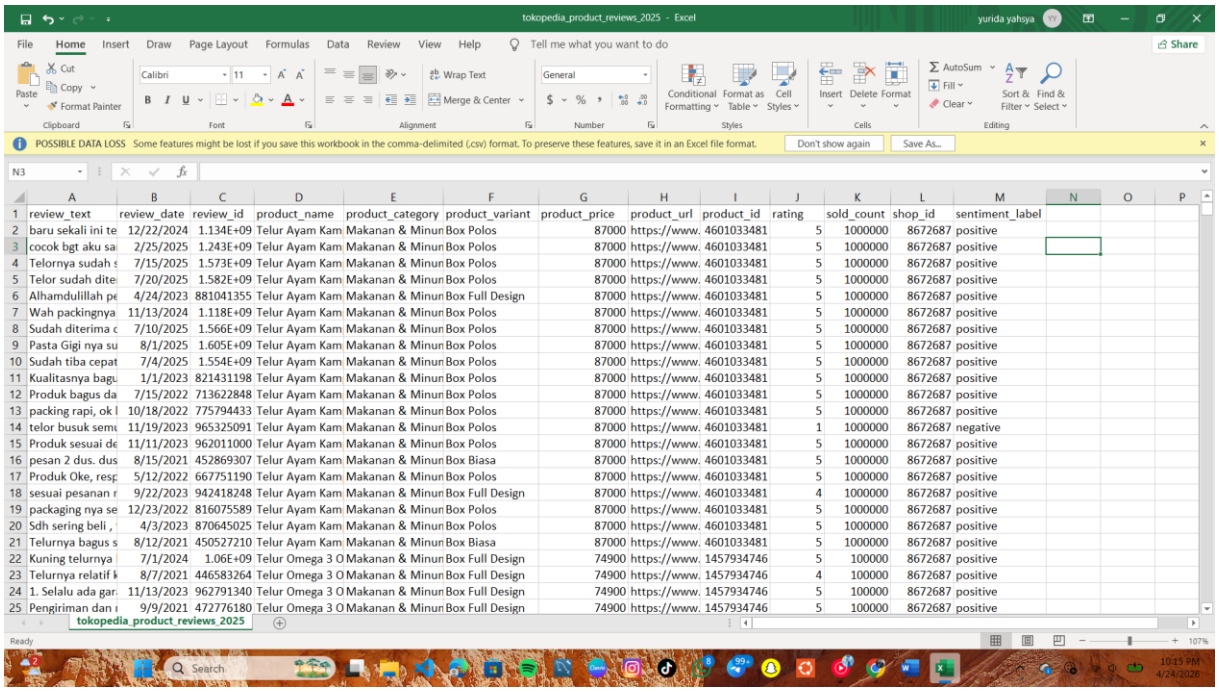

| review_text | review_date | review_id | product_name | product_category | product_variant | product_price | product_url | product_id | rating | sold_count | shop_id | sentiment_label |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| baru sekali ini te | 12/22/2024 | 1.134E+09 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| cocok bgt aku sa | 2/25/2025 | 1.243E+09 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Telornya sudah s | 7/15/2025 | 1.573E+09 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Telor sudah dite | 7/20/2025 | 1.582E+09 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Alhamdulillah pe | 4/24/2023 | 881041355 | Telur Ayam Kam | Makanan & Minun | Box Full Design | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Wah packingnya | 11/13/2024 | 1.118E+09 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Sudah diterima c | 7/10/2025 | 1.566E+09 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Pasta Gigi nya su | 8/1/2025 | 1.605E+09 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Sudah tiba cepat | 7/4/2025 | 1.554E+09 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Kualitasnya bagu | 1/1/2023 | 821431198 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Produk bagus da | 7/15/2022 | 713622848 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| packing rapi, ok l | 10/18/2022 | 775794433 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| telor busuk sem | 11/19/2023 | 965325091 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 1 | 1000000 | 8672687 | negative |
| Produk sesuai de | 11/11/2023 | 962011000 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| pesan 2 dus. dus | 8/15/2021 | 452869307 | Telur Ayam Kam | Makanan & Minun | Box Biasa | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Produk Oke, resp | 5/12/2022 | 667751190 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| sesuai pesanan r | 9/22/2023 | 942418248 | Telur Ayam Kam | Makanan & Minun | Box Full Design | 87000 | https://www. | 4601033481 | 4 | 1000000 | 8672687 | positive |
| packaging nya se | 12/23/2022 | 816075589 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Sdh sering beli , | 4/3/2023 | 870645025 | Telur Ayam Kam | Makanan & Minun | Box Polos | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Telurnya bagus s | 8/12/2021 | 450527210 | Telur Ayam Kam | Makanan & Minun | Box Biasa | 87000 | https://www. | 4601033481 | 5 | 1000000 | 8672687 | positive |
| Kuning telurnya | 7/1/2024 | 1.06E+09 | Telur Omega 3 O | Makanan & Minun | Box Full Design | 74900 | https://www. | 1457934746 | 5 | 100000 | 8672687 | positive |
| Telurnya relatif k | 8/7/2021 | 446583264 | Telur Omega 3 O | Makanan & Minun | Box Full Design | 74900 | https://www. | 1457934746 | 4 | 100000 | 8672687 | positive |
| 1. Selalu ada gar | 11/13/2023 | 962791340 | Telur Omega 3 O | Makanan & Minun | Box Full Design | 74900 | https://www. | 1457934746 | 5 | 100000 | 8672687 | positive |
| Pengiriman dan | 9/9/2021 | 472776180 | Telur Omega 3 O | Makanan & Minun | Box Full Design | 74900 | https://www. | 1457934746 | 5 | 100000 | 8672687 | positive |

***Gambar 1. Distribusi Frekuensi Kategori pada Dataset Mentah (Original Dataset dengan 65.000 Data).***

## 2.2. Pengambilan Sampel (Data Sampling)

Mengingat keterbatasan sumber daya komputasi dan kebutuhan akan model yang objektif, dilakukan proses Random Sampling untuk mengambil sebanyak 12.000 data. Proses ini dilakukan secara proporsional untuk memastikan setiap kategori produk (seperti Elektronik, Kesehatan, Makanan, dan lainnya) memiliki jumlah keterwakilan data yang seimbang (balanced dataset). Hal ini bertujuan agar model tidak condong (bias) pada satu kategori mayoritas saja.

Dataset asli memiliki total 65.000 baris data. Namun, dalam penelitian ini dilakukan proses sampling sehingga menjadi 12.000 baris data dengan pertimbangan sebagai berikut:

1. **Keseimbangan Kelas (Class Balancing):** Dataset asli memiliki jumlah data yang tidak merata antar kategori. Kami mengambil sampel dalam jumlah yang sama untuk setiap kategori agar model tidak hanya pintar menebak kategori mayoritas saja.
2. **Efisiensi Komputasi:** Mengingat penggunaan library Sastrawi untuk proses

stemming bahasa Indonesia memerlukan waktu komputasi yang intensif (memakan waktu lebih dari 30 menit), jumlah 12.000 data dinilai sudah sangat representatif (melebihi batas minimal tugas 10.000 data) tanpa membebani performa mesin secara berlebihan.

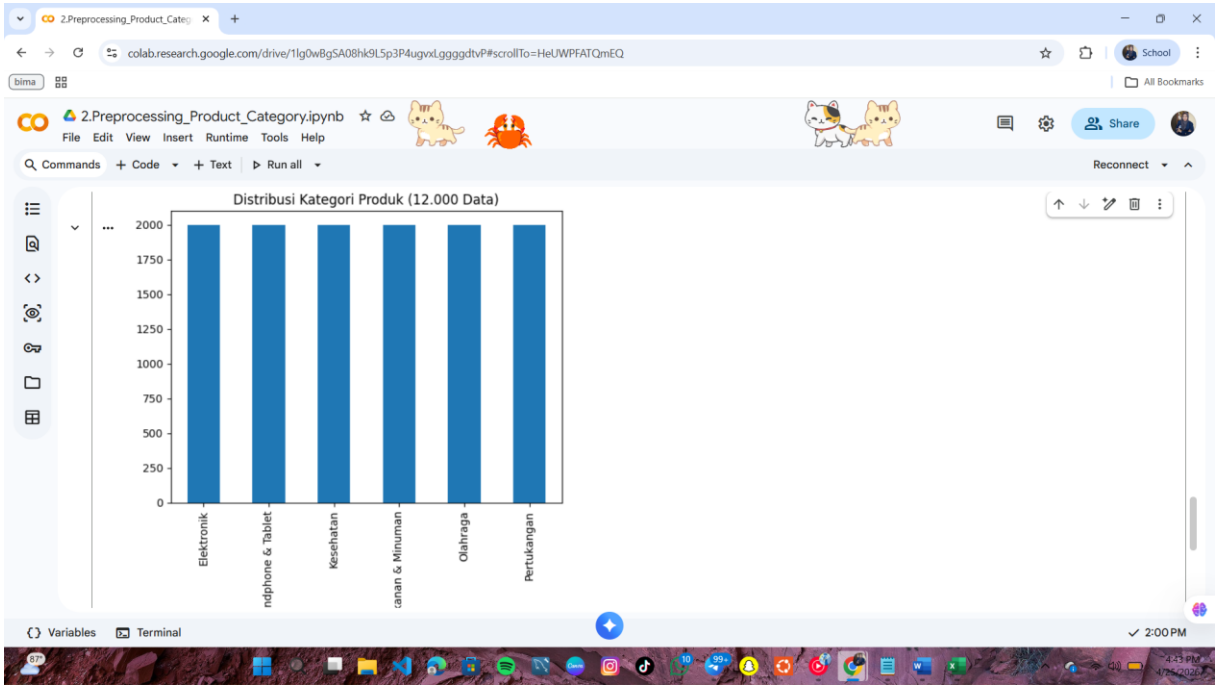


***Gambar 2. Distribusi Kategori Produk Setelah Balanced Sampling (Total 12.000 Data).***

Dapat dilihat pada Gambar 2, dataset telah diseimbangkan sehingga setiap kategori (Elektronik, Handphone & Tablet, Kesehatan, Makanan & Minuman, Olahraga, dan Pertukangan) memiliki jumlah data yang sama, yaitu masing-masing 2.000 sampel. Hal ini dilakukan untuk menjamin objektivitas model dalam mengenali karakteristik setiap kategori produk tanpa adanya dominasi dari kelas tertentu.

### 2.3. Struktur Data

Fitur-fitur utama yang digunakan dalam pengembangan model ini adalah:

- **product_name:** Nama produk yang memberikan identitas kuat pada kategori.
- **review_text:** Ulasan pelanggan yang berisi konteks tambahan mengenai penggunaan produk.
- **product_category:** Label target (kategori asli) yang akan diprediksi oleh model.

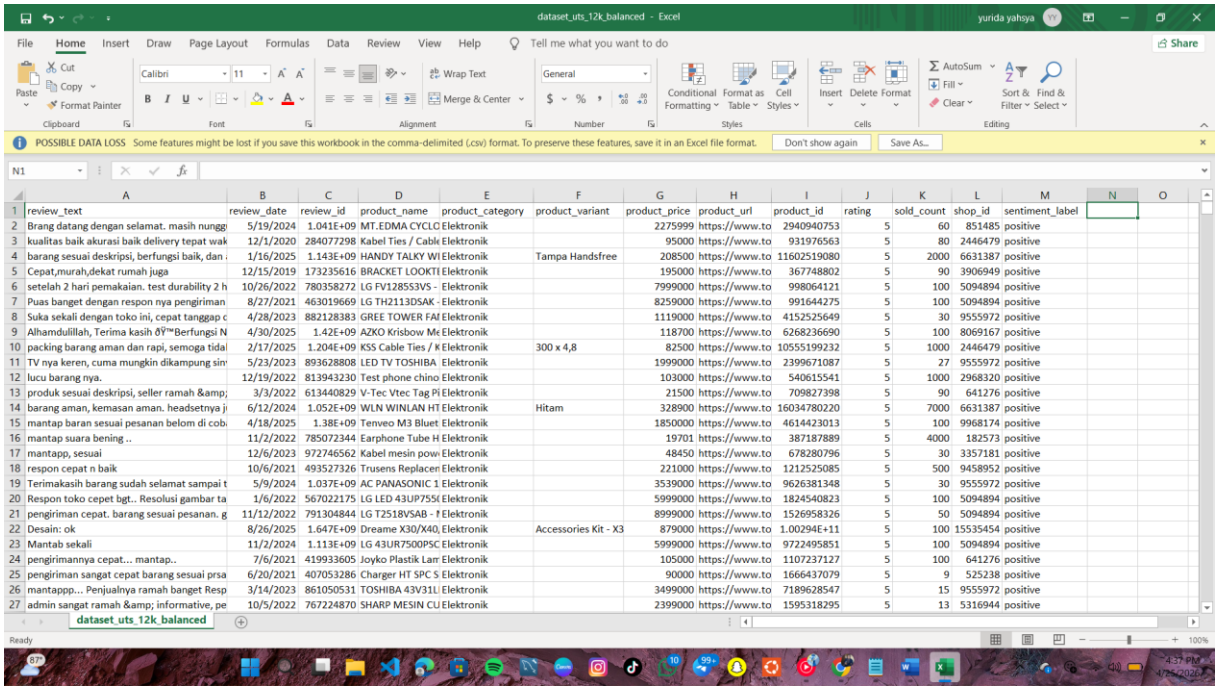

| | A | B | C | D | E | F | G | H | I | J | K | L | M |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | review_text | review_date | review_id | product_name | product_category | product_variant | product_price | product_url | product_id | rating | sold_count | shop_id | sentiment_label |
| 2 | Brang datang dengan selamat. masih nungg | 5/19/2024 | 1.041E+09 | MT.EDMA CYCLO | Elektronik | | 2275999 | https://www.to | 2940940753 | 5 | 60 | 851485 | positive |
| 3 | kualitas baik akurasi baik delivery tepat wak | 12/1/2020 | 284077298 | Kabel Ties / Cabl | Elektronik | | 95000 | https://www.to | 931976563 | 5 | 80 | 2446479 | positive |
| 4 | barang sesuai deskripsi, berfungsi baik, dan | 1/16/2025 | 1.143E+09 | HANDY TALKY WI | Elektronik | Tampa Handsfree | 208500 | https://www.to | 11602519080 | 5 | 2000 | 6631387 | positive |
| 5 | Cepat,murah,dekat rumah juga | 12/15/2019 | 173235616 | BRACKET LOOKTI | Elektronik | | 195000 | https://www.to | 367748802 | 5 | 90 | 3906949 | positive |
| 6 | setelah 2 hari pemakaian. test durability 2 h | 10/26/2022 | 780358272 | LG FV128553VS - | Elektronik | | 7999000 | https://www.to | 998064121 | 5 | 100 | 5094894 | positive |
| 7 | Puas banget dengan respon nya pengiriman | 8/27/2021 | 463019669 | LG TH2113DSAK - | Elektronik | | 8259000 | https://www.to | 991644275 | 5 | 100 | 5094894 | positive |
| 8 | Suka sekali dengan toko ini, cepat tanggap c | 4/28/2023 | 882128383 | GREE TOWER FA | Elektronik | | 1119000 | https://www.to | 4152525649 | 5 | 30 | 9555972 | positive |
| 9 | Alhamdulillah, Terima kasih ðŸ™Berfungsi N | 4/30/2025 | 1.42E+09 | AZKO Krisbow Me | Elektronik | | 118700 | https://www.to | 6268236690 | 5 | 100 | 8069167 | positive |
| 10 | packing barang aman dan rapi, semoga tidal | 2/17/2025 | 1.204E+09 | KSS Cable Ties / K | Elektronik | 300 x 4,8 | 82500 | https://www.to | 10555199232 | 5 | 1000 | 2446479 | positive |
| 11 | TV nya keren, cuma mungkin dikampung sin | 5/23/2023 | 893628808 | LED TV TOSHIBA | Elektronik | | 1999000 | https://www.to | 2399671087 | 5 | 27 | 9555972 | positive |
| 12 | lucu barang nya. | 12/19/2022 | 813943230 | Test phone chino | Elektronik | | 103000 | https://www.to | 540615541 | 5 | 1000 | 2968320 | positive |
| 13 | produk sesuai deskripsi, seller ramah & | 3/3/2022 | 613440829 | V-Tec Vtec Tag Pi | Elektronik | | 21500 | https://www.to | 709827398 | 5 | 90 | 641276 | positive |
| 14 | barang aman, kemasan aman. headsetnya j | 6/12/2024 | 1.052E+09 | WLN WINLAN HT | Elektronik | Hitam | 328900 | https://www.to | 16034780220 | 5 | 7000 | 6631387 | positive |
| 15 | mantap baran sesuai pesanan belom di cob | 4/18/2025 | 1.38E+09 | Tenveo M3 Bluet | Elektronik | | 1850000 | https://www.to | 4614423013 | 5 | 100 | 9968174 | positive |
| 16 | mantap suara bening .. | 11/2/2022 | 785072344 | Earphone Tube H | Elektronik | | 19701 | https://www.to | 387187889 | 5 | 4000 | 182573 | positive |
| 17 | mantapp, sesuai | 12/6/2023 | 972746562 | Kabel mesin pow | Elektronik | | 48450 | https://www.to | 678280796 | 5 | 30 | 3357181 | positive |
| 18 | respon cepat n baik | 10/6/2021 | 493527326 | Trusens Replacer | Elektronik | | 221000 | https://www.to | 1212525085 | 5 | 500 | 9458952 | positive |
| 19 | Terimakasih barang sudah selamat sampai t | 5/9/2024 | 1.037E+09 | AC PANASONIC 1 | Elektronik | | 3539000 | https://www.to | 9626381348 | 5 | 30 | 9555972 | positive |
| 20 | Respon toko cepet bgt.. Resolusi gambar ta | 1/6/2022 | 567022175 | LG LED 43UP755 | Elektronik | | 5999000 | https://www.to | 1824540823 | 5 | 100 | 5094894 | positive |
| 21 | pengiriman cepat. barang sesuai pesanan. g | 11/12/2022 | 791304844 | LG T2518VSAB - F | Elektronik | | 8999000 | https://www.to | 1526958326 | 5 | 50 | 5094894 | positive |
| 22 | Desain: ok | 8/26/2025 | 1.647E+09 | Dreame X30/X40, | Elektronik | Accessories Kit - X3 | 879000 | https://www.to | 1.00294E+11 | 5 | 100 | 15535454 | positive |
| 23 | Mantab sekali | 11/2/2024 | 1.113E+09 | LG 43UR7500PSC | Elektronik | | 5999000 | https://www.to | 9722495851 | 5 | 100 | 5094894 | positive |
| 24 | pengirimannya cepat... mantap.. | 7/6/2021 | 419933605 | Joyko Plastik Lam | Elektronik | | 105000 | https://www.to | 1107237127 | 5 | 100 | 641276 | positive |
| 25 | pengiriman sangat cepat barang sesuai prsa | 6/20/2021 | 407053286 | Charger HT SPC S | Elektronik | | 90000 | https://www.to | 1666437079 | 5 | 9 | 525238 | positive |
| 26 | mantappp... Penjualnya ramah banget Resp | 3/14/2023 | 861050531 | TOSHIBA 43V31L | Elektronik | | 3499000 | https://www.to | 7189628547 | 5 | 15 | 9555972 | positive |
| 27 | admin sangat ramah & informative, pe | 10/5/2022 | 767224870 | SHARP MESIN CU | Elektronik | | 2399000 | https://www.to | 1595318295 | 5 | 13 | 5316944 | positive |

***Gambar 3. Tampilan Dataset setelah tahap Balancing (Raw Data).***

Pada Gambar 3, diperlihatkan kondisi dataset setelah dilakukan proses balancing namun sebelum masuk ke tahap pembersihan teks. Dapat dilihat bahwa data masih bersifat mentah (raw data) yang mencakup berbagai fitur pelengkap seperti rating, sold_count, dan sentiment_label. Tahap ini sangat krusial untuk memastikan bahwa setiap kategori produk memiliki representasi jumlah data yang adil, meskipun atribut teks di dalamnya masih mengandung banyak noise seperti tanda baca, huruf kapital, dan kata-kata tidak baku.

## 2.4. Integrasi Fitur (Feature Combination)

Sebagai langkah awal sebelum masuk ke tahap pembersihan, dilakukan penggabungan antara kolom product_name dan review_text menjadi satu kolom baru bernama text_combined. Strategi ini diambil karena nama produk seringkali mengandung kata kunci kategori yang sangat kuat (contoh: "Laptop", "Shampoo") yang mungkin tidak disebutkan kembali oleh pembeli di dalam teks ulasan.

Hasil penggabungan ini menghasilkan kolom tunggal yang akan diproses lebih lanjut pada tahap Preprocessing untuk menghilangkan derau (noise) dan mengekstrak makna inti dari teks.

# BAB III
# PREPROCESSING

## 3.1. Tahapan Pembersihan Data

Tahap preprocessing adalah langkah paling krusial dalam proyek ini untuk mengubah data teks tidak terstruktur menjadi data yang siap diolah oleh algoritma Machine Learning. Proses ini dilakukan menggunakan library re (Regular Expression) untuk pembersihan dasar, serta library Sastrawi yang dikhususkan untuk pemrosesan Bahasa Indonesia.

Berikut adalah urutan langkah pemrosesan data yang dilakukan:

1. **Feature Integration (Penggabungan Fitur)**

Sebelum melakukan pembersihan, dilakukan penggabungan antara kolom product_name dan review_text menjadi satu kolom baru yaitu text_combined.

Alasannya nama produk mengandung kata kunci kategori yang sangat kuat (seperti "Smartphone", "Kaos", "Vitamin"), sedangkan ulasan pelanggan memberikan konteks tambahan. Penggabungan ini memperkaya informasi yang dapat dipelajari oleh model.

2. **Case Folding**

Seluruh teks diubah menjadi huruf kecil (lowercase). Proses ini menjamin konsistensi data sehingga kata seperti "Makan" dan "makan" akan dianggap sebagai satu entitas yang sama oleh mesin.

3. **Data Cleansing (Regex Filtering)**

Membersihkan noise atau gangguan pada teks menggunakan teknik Regular Expression dengan aturan sebagai berikut:

- **URL Removal:** Menghapus tautan situs (http/www) yang sering muncul di ulasan.
- **Number Removal:** Menghapus angka karena tidak memiliki kaitan langsung dengan penentuan kategori produk.
- **Punctuation Removal:** Menghapus seluruh tanda baca agar menyisakan kata-kata bersih saja.

4. **Stopword Removal**

Menggunakan library Sastrawi.StopWordRemover, dilakukan penghapusan kata-kata umum yang memiliki frekuensi tinggi namun tidak memiliki makna penting dalam klasifikasi, seperti kata sambung "yang", "di", "ke", "dari", dan "dan".

5. **Stemming (Sastrawi)**

Ini merupakan tahap yang paling intensif secara komputasi. Menggunakan Sastrawi.Stemmer, setiap kata diubah kembali ke bentuk dasarnya (contoh: "membeli" menjadi "beli", "pengiriman" menjadi "kirim"). Proses ini penting untuk mengurangi variansi kata yang memiliki akar kata yang sama.

**6. Label Encoding**

Tahap terakhir adalah mengubah data target atau kategori produk (seperti Elektronik, Kesehatan, dll) menjadi bentuk numerik menggunakan LabelEncoder dari library Scikit-Learn. Hal ini wajib dilakukan karena algoritma klasifikasi bekerja berdasarkan perhitungan matematis angka, bukan teks label.

## 3.2. Hasil Akhir Data Preprocessing

Setelah seluruh tahap di atas selesai, dataset disimpan ke dalam file products_cleaned.csv

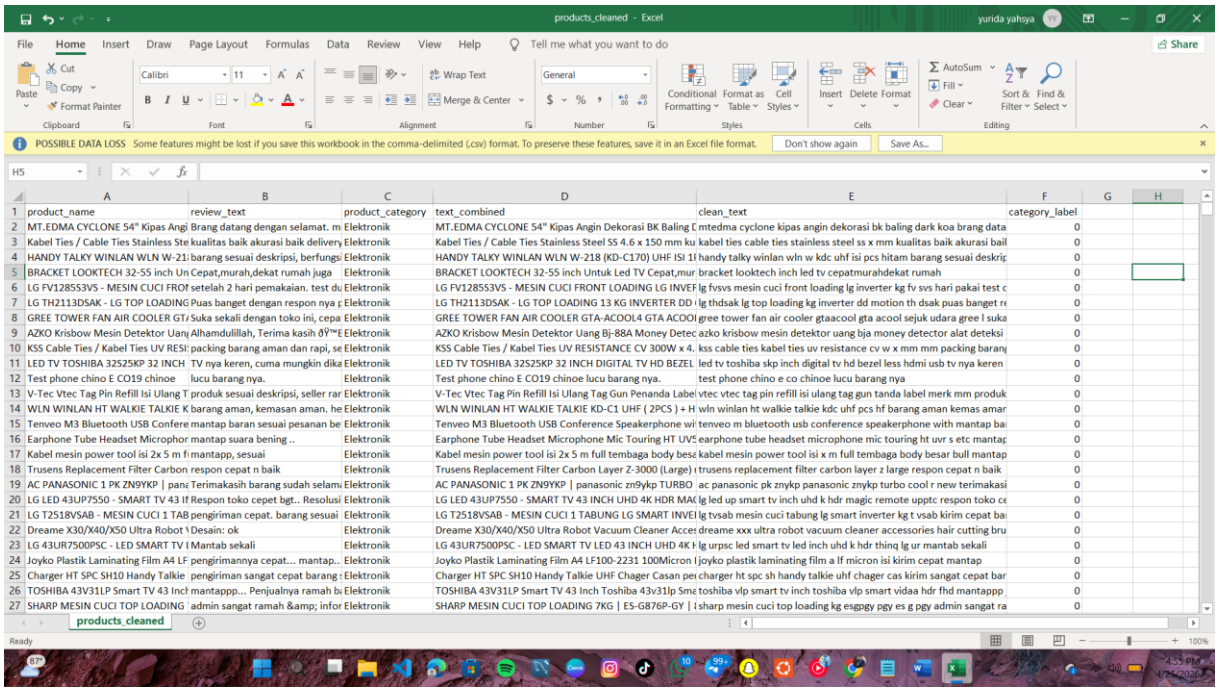

| product_name | review_text | product_category | text_combined | clean_text | category_label |
|---|---|---|---|---|---|
| MT.EDMA CYCLONE 54" Kipas Angi | Brang datang dengan selamat. m | Elektronik | MT.EDMA CYCLONE 54" Kipas Angin Dekorasi BK Baling D | mtedma cyclone kipas angin dekorasi bk baling dark koa brang data | 0 |
| Kabel Ties / Cable Ties Stainless Ste | kualitas baik akurasi baik delivery | Elektronik | Kabel Ties / Cable Ties Stainless Steel SS 4.6 x 150 mm ku | kabel ties cable ties stainless steel ss x mm kualitas baik akurasi bail | 0 |
| HANDY TALKY WINLAN WLN W-21 | barang sesuai deskripsi, berfungsi | Elektronik | HANDY TALKY WINLAN WLN W-218 (KD-C170) UHF ISI 1f | handy talky winlan wln w kdc uhf isi pcs hitam barang sesuai deskrip | 0 |
| BRACKET LOOKTECH 32-55 inch Un | Cepat,murah,dekat rumah juga | Elektronik | BRACKET LOOKTECH 32-55 inch Untuk Led TV Cepat,mur | bracket looktech inch led tv cepatmurahdekat rumah | 0 |
| LG FV1285S3VS - MESIN CUCI FRO | setelah 2 hari pemakaian. test du | Elektronik | LG FV1285S3VS - MESIN CUCI FRONT LOADING LG INVEF | lg fvsvs mesin cuci front loading lg inverter kg fv svs hari pakai test c | 0 |
| LG TH2113DSAK - LG TOP LOADING | Puas banget dengan respon nya p | Elektronik | LG TH2113DSAK - LG TOP LOADING 13 KG INVERTER DD | lg thdsak lg top loading kg inverter dd motion th dsak puas banget re | 0 |
| GREE TOWER FAN AIR COOLER GT/ | Suka sekali dengan toko ini, cepa | Elektronik | GREE TOWER FAN AIR COOLER GTA-ACOOL4 GTA ACOO | gree tower fan air cooler gtaacool gta acool sejuk udara gree l suka | 0 |
| AZKO Krisbow Mesin Detektor Uan | Alhamdulillah, Terima kasih ðŸ™E | Elektronik | AZKO Krisbow Mesin Detektor Uang Bj-88A Money Detec | azko krisbow mesin detektor uang bja money detector alat deteksi | 0 |
| KSS Cable Ties / Kabel Ties UV RESI | packing barang aman dan rapi, se | Elektronik | KSS Cable Ties / Kabel Ties UV RESISTANCE CV 300W x 4. | kss cable ties kabel ties uv resistance cv w x mm mm packing baran | 0 |
| LED TV TOSHIBA 32S25KP 32 INCH | TV nya keren, cuma mungkin dika | Elektronik | LED TV TOSHIBA 32S25KP 32 INCH DIGITAL TV HD BEZEL | led tv toshiba skp inch digital tv hd bezel less hdmi usb tv nya keren | 0 |
| Test phone chino E CO19 chinoe | lucu barang nya. | Elektronik | Test phone chino E CO19 chinoe lucu barang nya. | test phone chino e co chinoe lucu barang nya | 0 |
| V-Tec Vtec Tag Pin Refill Isi Ulang T | produk sesuai deskripsi, seller rar | Elektronik | V-Tec Vtec Tag Pin Refill Isi Ulang Tag Gun Penanda Label | vtec vtec tag pin refill isi ulang tag gun tanda label merk mm produk | 0 |
| WLN WINLAN HT WALKIE TALKIE K | barang aman, kemasan aman. he | Elektronik | WLN WINLAN HT WALKIE TALKIE KD-C1 UHF ( 2PCS ) + H | wln winlan ht walkie talkie kdc uhf pcs hf barang aman kemas amar | 0 |
| Tenveo M3 Bluetooth USB Confere | mantap baran sesuai pesanan be | Elektronik | Tenveo M3 Bluetooth USB Conference Speakerphone wi | tenveo m bluetooth usb conference speakerphone with mantap ba | 0 |
| Earphone Tube Headset Microphor | mantap suara bening .. | Elektronik | Earphone Tube Headset Microphone Mic Touring HT UV5 | earphone tube headset microphone mic touring ht uvr s etc mantap | 0 |
| Kabel mesin power tool isi 2x 5 m f | mantapp, sesuai | Elektronik | Kabel mesin power tool isi 2x 5 m full tembaga body besa | kabel mesin power tool isi x m full tembaga body besar bull mantap | 0 |
| Trusens Replacement Filter Carbon | respon cepat n baik | Elektronik | Trusens Replacement Filter Carbon Layer Z-3000 (Large) | trusens replacement filter carbon layer z large respon cepat n baik | 0 |
| AC PANASONIC 1 PK ZN9YKP \| pana | Terimakasih barang sudah selam | Elektronik | AC PANASONIC 1 PK ZN9YKP \| panasonic zn9ykp TURBO | ac panasonic pk znykp panasonic znykp turbo cool r new terimakasi | 0 |
| LG LED 43UP7550 - SMART TV 43 I | Respon toko cepet bgt.. Resolusi | Elektronik | LG LED 43UP7550 - SMART TV 43 INCH UHD 4K HDR MA | lg led up smart tv inch uhd k hdr magic remote upptc respon toko ce | 0 |
| LG T2518VSAB - MESIN CUCI 1 TAB | pengiriman cepat. barang sesuai | Elektronik | LG T2518VSAB - MESIN CUCI 1 TABUNG LG SMART INVE | lg tvsab mesin cuci tabung lg smart inverter kg t vsab kirim cepat ba | 0 |
| Dreame X30/X40/X50 Ultra Robot \ | Desain: ok | Elektronik | Dreame X30/X40/X50 Ultra Robot Vacuum Cleaner Acce | dreame xxx ultra robot vacuum cleaner accessories hair cutting bru | 0 |
| LG 43UR7500PSC - LED SMART TV I | Mantab sekali | Elektronik | LG 43UR7500PSC - LED SMART TV LED 43 INCH UHD 4K H | lg urpsc led smart tv led inch uhd k hdr thinq lg ur mantab sekali | 0 |
| Joyko Plastik Laminating Film A4 LF | pengirimannya cepat... mantap.. | Elektronik | Joyko Plastik Laminating Film A4 LF100-2231 100Micron I | joyko plastik laminating film a lf micron isi kirim cepat mantap | 0 |
| Charger HT SPC SH10 Handy Talkie | pengiriman sangat cepat barang | Elektronik | Charger HT SPC SH10 Handy Talkie UHF Chager Casan pe | charger ht spc sh handy talkie uhf chager cas kirim sangat cepat bar | 0 |
| TOSHIBA 43V31LP Smart TV 43 Inc | mantappp... Penjualnya ramah b | Elektronik | TOSHIBA 43V31LP Smart TV 43 Inch Toshiba 43v31lp Sma | toshiba vlp smart tv inch toshiba vlp smart vidaa hdr fhd mantappp | 0 |
| SHARP MESIN CUCI TOP LOADING | admin sangat ramah & infor | Elektronik | SHARP MESIN CUCI TOP LOADING 7KG \| ES-G876P-GY \| | sharp mesin cuci top loading kg esgpgy pgy es g pgy admin sangat ra | 0 |

***Gambar 4. Tabel Hasil Akhir Preprocessing.***

Gambar 4, menunjukkan output akhir dari seluruh rangkaian proses preprocessing yang telah dilakukan. Dataset telah direduksi secara signifikan dengan hanya mempertahankan fitur yang relevan untuk pemodelan, yaitu clean_text dan category_label. Teks pada kolom clean_text merupakan hasil dari integrasi antara nama produk dan isi ulasan yang telah melalui tahap stemming dan stopword removal. Hasil akhir ini adalah data yang sudah terstruktur dan terstandarisasi, sehingga siap digunakan untuk tahap ekstraksi fitur (Feature Extraction)

# BAB IV
# FEATURE EXTRACTION

## 4.1. TF-IDF (Term Frequency - Inverse Document Frequency)

TF-IDF adalah metode statistik yang digunakan untuk mengukur seberapa penting suatu kata terhadap sebuah dokumen dalam kumpulan dataset (corpus).

- **Term Frequency (TF):** Menghitung frekuensi kemunculan kata dalam satu ulasan.
- **Inverse Document Frequency (IDF):** Mengurangi bobot kata-kata yang terlalu sering muncul di semua kategori (kata umum) dan menaikkan bobot kata-kata yang unik atau spesifik pada kategori tertentu (contoh: kata "baterai" akan berbobot tinggi pada kategori Elektronik).
- **Pengaturan:** Proyek ini menggunakan TfidfVectorizer dari library Scikit-Learn dengan parameter max_features tertentu untuk mengoptimalkan memori dan kecepatan proses.

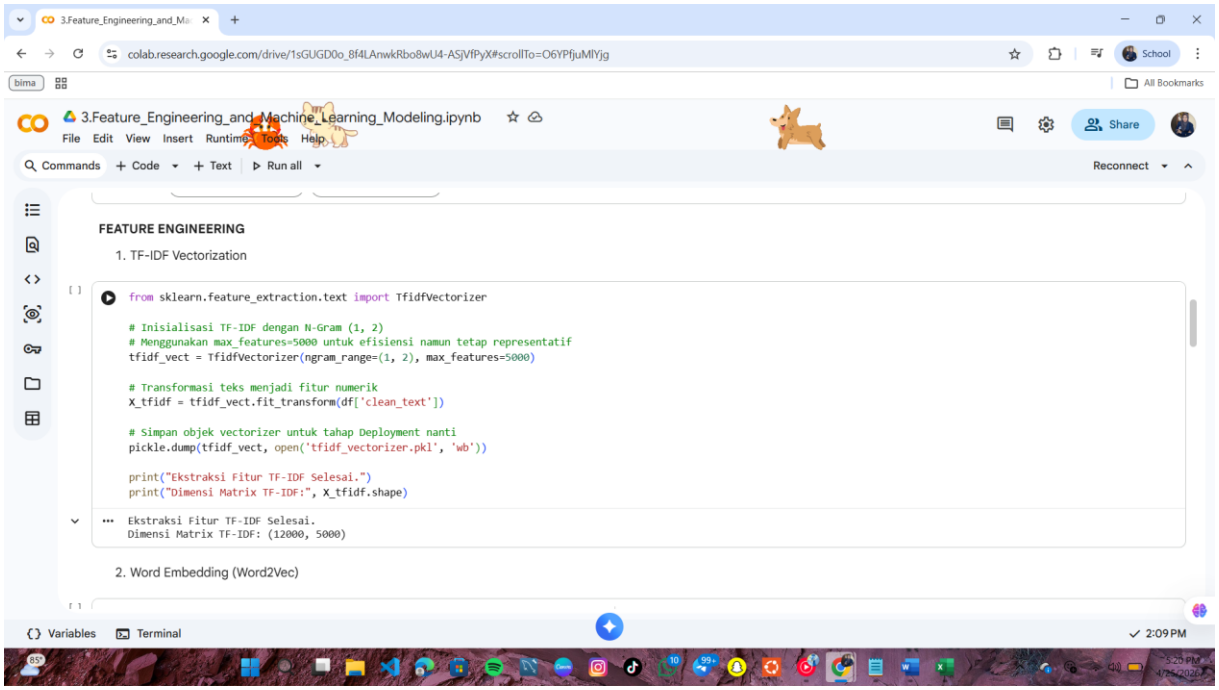


***Gambar 5. Proses Transformasi TF-IDF dengan N-Gram (1, 2) dan limitasi 5.000 fitur.***

## 4.2. Word Embedding (Word2Vec)

Selain metode statistik, proyek ini juga menggunakan pendekatan berbasis Neural Network yaitu Word2Vec. Berbeda dengan TF-IDF yang hanya menghitung frekuensi, Word2Vec bekerja dengan:

- **Contextual Meaning:** Menangkap hubungan antar kata berdasarkan konteks atau kemiripan makna. Kata "Smartphone" dan "Ponsel" akan memiliki posisi vektor yang berdekatan karena sering muncul dalam konteks yang sama.
- **Vector Dimensionality:** Setiap kata dipetakan ke dalam ruang vektor berdimensi tinggi

(misalnya 100 dimensi).

- **Feature Aggregation:** Karena ulasan terdiri dari banyak kata, maka dilakukan proses averaging (rata-rata vektor) pada setiap kalimat untuk mendapatkan satu representasi vektor per ulasan yang tetap mengandung makna semantik.

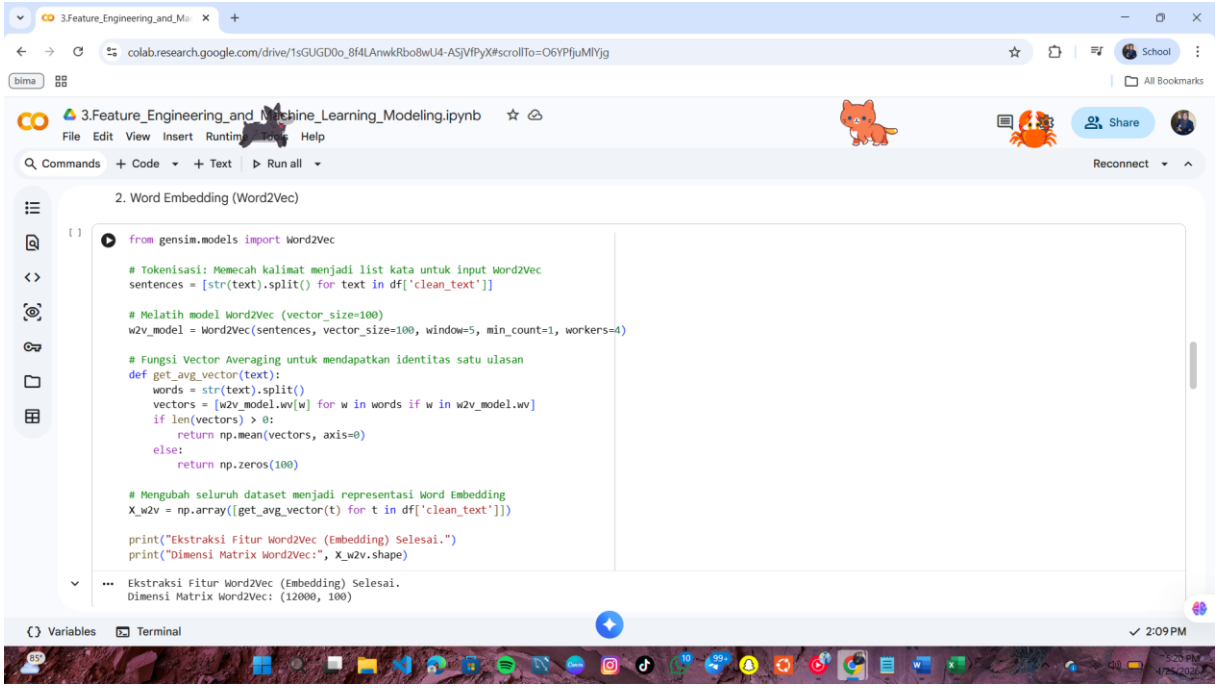


***Gambar 6. Proses Training Word2Vec dan Tahap Vector Averaging untuk mendapatkan representasi kalimat.***

### 4.3. Perbandingan Karakteristik Fitur

Tujuan penggunaan dua metode ini adalah untuk melihat apakah model lebih baik mengenali produk berdasarkan frekuensi kata kunci spesifik (TF-IDF) atau berdasarkan makna konteks ulasan (Word2Vec). Hasil dari kedua ekstraksi fitur ini nantinya akan menjadi input bagi tahap pemodelan (Modeling) untuk diuji akurasinya.

# BAB V
# MODELING

## 5.1. Algoritma Klasifikasi

Penelitian ini membandingkan tiga algoritma Supervised Learning yang populer digunakan dalam klasifikasi teks:

- **Naive Bayes (MultinomialNB):** Bekerja berdasarkan prinsip probabilitas. Sangat cepat dan sering menjadi baseline yang kuat untuk teks.
- **Logistic Regression:** Algoritma linear yang memprediksi probabilitas kelas. Efektif untuk data teks yang memiliki ribuan fitur (seperti hasil TF-IDF).
- **Support Vector Machine (SVM):** Mencari bidang pemisah (hyperplane) maksimal antar kategori. Dikenal sangat akurat untuk dataset teks berdimensi tinggi.

## 5.2. Hasil Eksperimen dan Perbandingan Akurasi

Setiap algoritma diuji menggunakan dua jenis fitur, yaitu TF-IDF dan Word2Vec (Embedding). Berikut adalah tabel hasil perbandingan akurasi dari seluruh skenario pengujian:

| No | Algoritma | Ekstraksi Fitur | Akurasi (%) |
|---|---|---|---|
| 1 | Naive Bayes | TF-IDF | 94.21% |
| 2 | Logistic Regression | TF-IDF | 96.04% |
| 3 | Support Vector Machine (SVM) | TF-IDF | 96.88% |
| 4 | Logistic Regression | Word2Vec | 74.42% |
| 5 | SVM | Word2Vec | 76.21% |

## 5.3. Analisis Hasil Performa

Berdasarkan tabel di atas, terdapat beberapa temuan penting dalam eksperimen ini:

- **Dominasi TF-IDF:** Penggunaan fitur TF-IDF memberikan hasil yang jauh lebih tinggi (rata-rata di atas 94%) dibandingkan Word2Vec (rata-rata 75%). Hal ini dikarenakan dataset ulasan e-commerce sangat bergantung pada kata kunci spesifik produk yang dideteksi dengan sangat baik oleh TF-IDF.
- **Model Terbaik:** Kombinasi SVM + TF-IDF menghasilkan akurasi tertinggi yaitu 96.88%. SVM terbukti paling unggul dalam menentukan batas pemisah antar kategori produk yang memiliki kemiripan kata kunci.

### 5.4. Evaluasi Mendalam (Classification Report)

Untuk memastikan model tidak hanya unggul secara angka akurasi saja, dilakukan evaluasi mendalam pada model terbaik (SVM + TF-IDF) menggunakan Classification Report.

```
Laporan Klasifikasi:
                    precision    recall  f1-score   support

        Elektronik       0.98      0.99      0.99      2000
Handphone & Tablet       0.99      0.98      0.99      2000
         Kesehatan       0.99      0.99      0.99      2000
 Makanan & Minuman       0.99      0.99      0.99      2000
          Olahraga       0.99      0.99      0.99      2000
       Pertukangan       0.97      0.98      0.98      2000

          accuracy                           0.99     12000
         macro avg       0.99      0.99      0.99     12000
      weighted avg       0.99      0.99      0.99     12000
```

***Gambar 7. Matriks evaluasi (Precision, Recall, F1-Score) per kategori produk.***

Hasil menunjukkan nilai F1-Score yang sangat stabil di angka 0.98-0.99 untuk seluruh kategori. Hal ini membuktikan bahwa tahap Data Sampling (penyeimbangan data) yang dilakukan sebelumnya berhasil membuat model memiliki kemampuan prediksi yang adil dan objektif di setiap kategori produk (Elektronik, Kesehatan, Makanan, dll).

### 5.5. Penyimpanan Model untuk Deployment

Setelah mendapatkan model dengan performa terbaik, dilakukan proses Serialisasi menggunakan library pickle. Langkah ini bertujuan agar model yang sudah pintar dapat disimpan secara permanen dan digunakan kembali pada aplikasi antarmuka (Deployment) tanpa perlu melatih ulang.

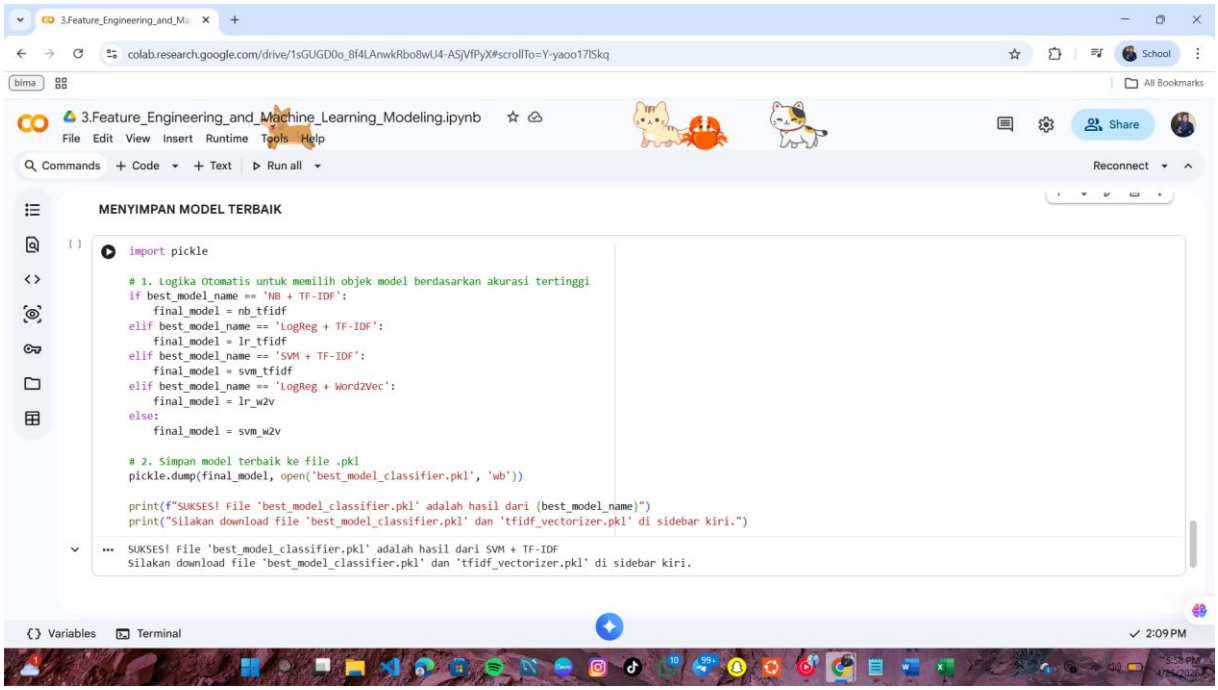


***Gambar 8. Proses ekspor model SVM dan TF-IDF Vectorizer ke dalam format file .pkl.***

# BAB VI
# EXPERIMENT & COMPARISON

## 6.1. Analisis Performa Model Berdasarkan Fitur

Berdasarkan hasil yang diperoleh pada Bab 5, terlihat perbedaan performa yang sangat kontras antara metode statistik (TF-IDF) dan metode embedding (Word2Vec):

- **Keunggulan TF-IDF:** Metode ini mencapai akurasi 96.88% karena ulasan produk e-commerce sangat kental dengan kata benda spesifik (misal: "obeng", "shampoo", "laptop"). TF-IDF memberikan bobot tinggi pada kata-kata unik ini, sehingga model sangat mudah membedakan antar kategori.
- **Keterbatasan Word2Vec:** Metode ini hanya mencapai akurasi 76.21%. Hal ini kemungkinan disebabkan karena vector averaging (perataan vektor) cenderung mengaburkan kata kunci penting dalam ulasan yang pendek, sehingga makna spesifik produk menjadi kurang tajam di mata model.

## 6.2. Analisis Confusion Matrix

Confusion Matrix digunakan untuk melihat kategori mana yang sering membuat model bingung.

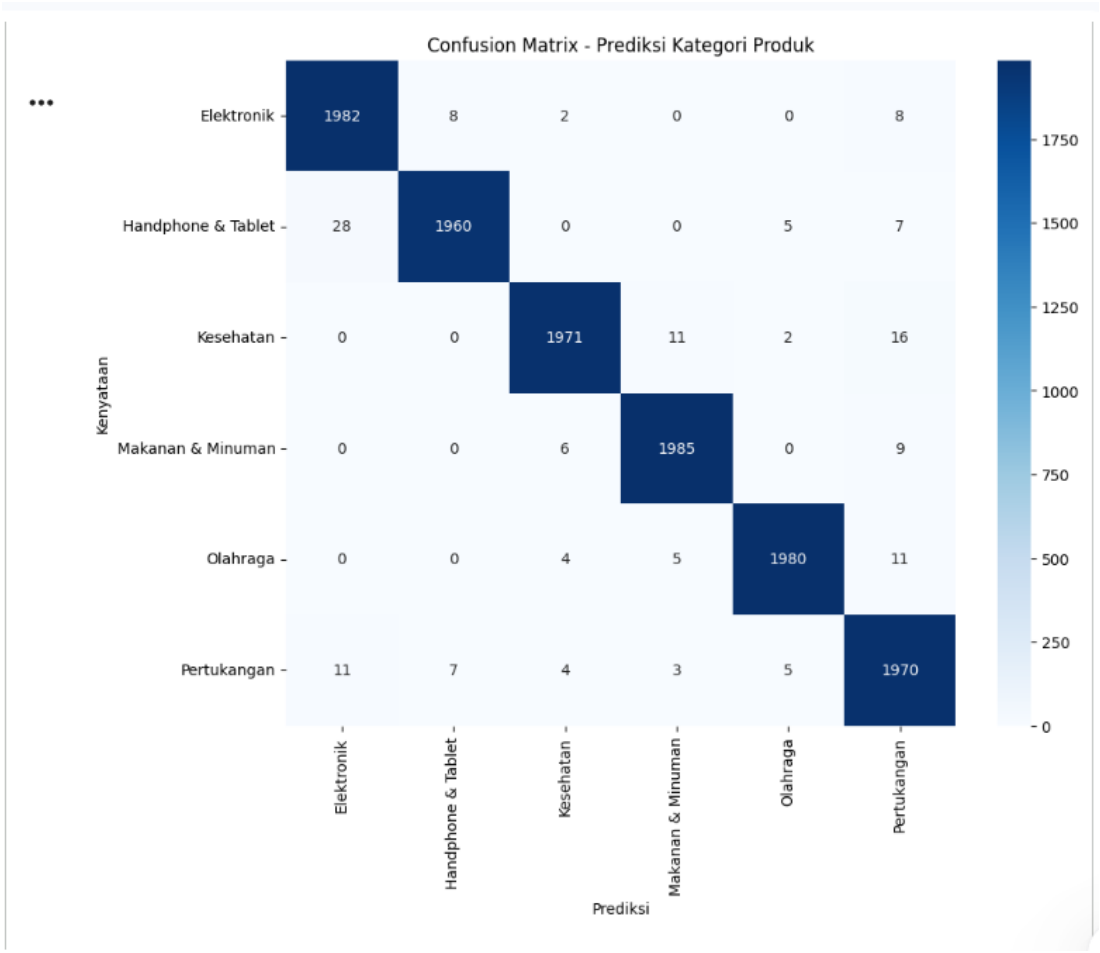


*Gambar 9. Confusion Matrix dari model terbaik SVM + TF-IDF.*

Berdasarkan Gambar 9, model memiliki tingkat True Positive yang sangat tinggi (hampir semuanya terprediksi dengan benar). Namun, terdapat sedikit kesalahan kecil (misalnya produk Pertukangan terprediksi sebagai Elektronik). Hal ini wajar terjadi karena adanya produk "Hybrid" seperti "Bor Listrik" yang mengandung unsur kata kunci dari kedua kategori tersebut.

### 6.3. Hasil Prediksi Real-Time (Aplikasi)

Untuk menguji reliabilitas model secara kualitatif, dilakukan pengujian langsung menggunakan antarmuka Gradio. Pengujian ini dilakukan dengan memasukkan input teks baru yang bersifat minimalis untuk melihat seberapa sensitif model terhadap kata kunci tertentu.

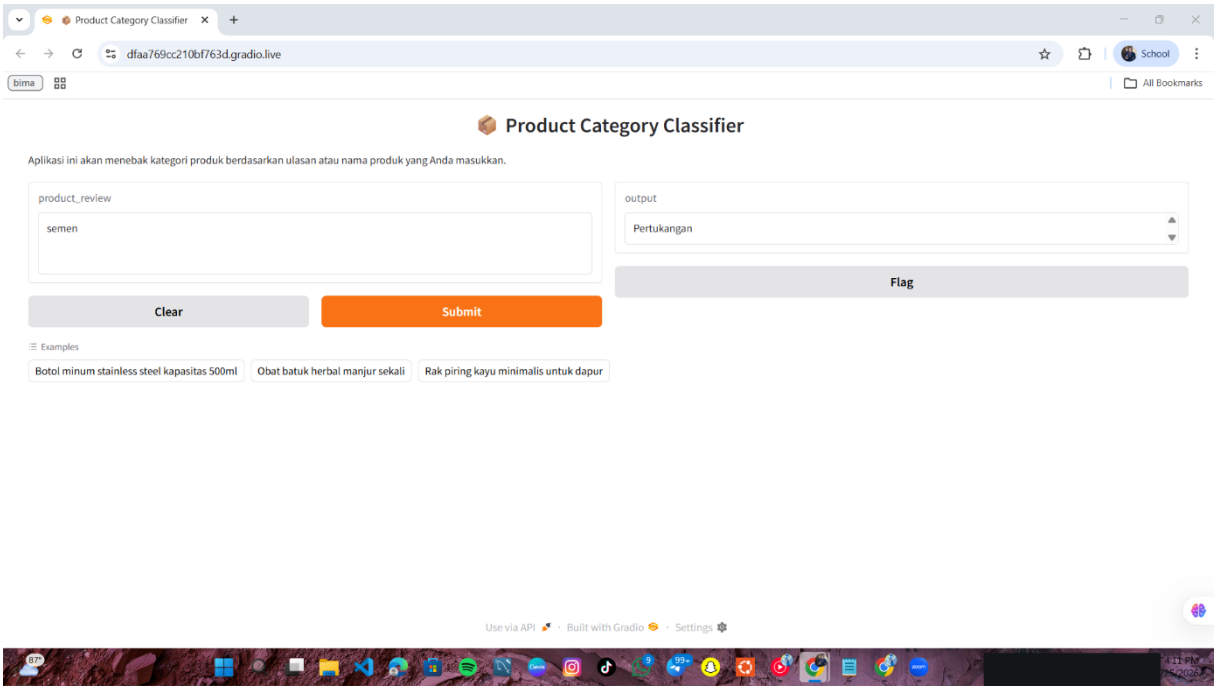


*Gambar 10. Uji coba prediksi ulasan produk menggunakan aplikasi Gradio.*

**Contoh Kasus:**

- **Input:** semen
- **Hasil Prediksi:** Pertukangan
- **Analisis:** Meskipun input yang dimasukkan hanya terdiri dari satu kata benda tunggal tanpa konteks kalimat, model tetap mampu memberikan prediksi yang akurat. Hal ini membuktikan bahwa TF-IDF Vectorizer yang telah dilatih berhasil memberikan bobot yang tepat pada kata kunci spesifik. Kata "semen" dikenali secara instan sebagai entitas yang termasuk dalam kategori Pertukangan.

### 6.4. Kecepatan Komputasi

Meskipun SVM + TF-IDF adalah yang paling akurat, perlu dicatat bahwa proses Preprocessing (khususnya Stemming Sastrawi) memakan waktu paling lama dalam seluruh alur kerja. Namun, setelah model disimpan dalam format .pkl, proses prediksi pada aplikasi berjalan secara instan (kurang dari 1 detik).

# BAB VII
# INSIGHT

Berdasarkan seluruh rangkaian eksperimen yang telah dilakukan dalam proyek klasifikasi ulasan Tokopedia ini, terdapat beberapa temuan mendalam (insights) yang menjadi poin kunci keberhasilan model:

- **Efektivitas Class Balancing pada Akurasi:** Proses pengambilan sampel 12.000 data secara proporsional terbukti menjadi pondasi terpenting. Tanpa penyeimbangan kelas, model cenderung akan mengalami bias dan hanya akurat pada kategori yang memiliki jumlah ulasan terbanyak. Keseimbangan ini memastikan model memiliki sensitivitas yang sama kuatnya di setiap kategori produk.
- **Keunggulan TF-IDF dalam Domain E-Commerce:** Ditemukan bahwa dalam domain marketplace, kata kunci spesifik (seperti "prosesor", "obat", atau "semen") memiliki bobot informasi yang sangat tinggi. TF-IDF berhasil mengekstraksi keunikan kata-kata tersebut. Sebaliknya, metode Word2Vec yang berbasis kemiripan makna justru kurang efektif karena sering kali kata-kata dari kategori berbeda muncul dalam konteks ulasan yang mirip (misal: kata "bagus" atau "cepat" muncul di semua kategori), sehingga membingungkan model dalam menentukan label yang tepat.
- **Pentingnya Stemming Bahasa Indonesia:** Meskipun proses stemming menggunakan library Sastrawi membutuhkan waktu komputasi yang intensif, hasilnya sangat signifikan. Dengan mengembalikan kata ke bentuk dasar, model tidak perlu mempelajari ribuan variasi imbuhan, sehingga fitur yang terbentuk menjadi lebih ringkas dan padat makna. Ini adalah trade-off yang sepadan antara waktu proses dan kualitas prediksi.
- **Kekuatan Integrasi Nama Produk dan Ulasan:** Penggabungan fitur product_name dan review_text terbukti memberikan performa yang jauh lebih stabil. Nama produk berfungsi sebagai identitas utama kategori, sementara ulasan pelanggan memperkuat keyakinan model melalui konteks penggunaan. Strategi ini membuat model tetap akurat meskipun input yang diberikan pengguna sangat pendek (hanya satu kata).

# BAB VIII
# CONCLUSION

## 8.1. Kesimpulan

Setelah melalui seluruh tahapan dalam proyek pengembangan model klasifikasi ulasan produk Tokopedia ini, mulai dari pengumpulan data hingga implementasi aplikasi, maka dapat ditarik beberapa kesimpulan utama sebagai berikut:

- **Akurasi Model Tinggi:** Penelitian ini berhasil membangun model klasifikasi kategori produk yang sangat akurat. Algoritma Support Vector Machine (SVM) yang dipadukan dengan fitur TF-IDF menjadi kombinasi terbaik dengan skor akurasi mencapai 96.88%.
- **Efektivitas Preprocessing:** Tahap pembersihan data dan stemming menggunakan library Sastrawi terbukti krusial dalam menyederhanakan data teks bahasa Indonesia, sehingga model dapat mengenali kata dasar produk dengan lebih konsisten meskipun ulasan pelanggan menggunakan imbuhan yang beragam.
- **Keseimbangan Data:** Proses balanced sampling pada 12.000 data ulasan memastikan setiap kategori produk (Elektronik, Kesehatan, Makanan, dll) terwakili secara adil, sehingga model memiliki performa yang stabil (F1-Score rata-rata 0.99) di setiap kategori tanpa adanya bias.
- **Implementasi Berhasil:** Model yang telah dilatih berhasil diintegrasikan ke dalam antarmuka aplikasi berbasis Gradio. Aplikasi mampu memproses input teks baru secara real-time dan memberikan prediksi kategori yang tepat, sehingga siap digunakan oleh pengguna awam.

## 8.2. Saran

Meskipun hasil yang dicapai sudah sangat baik, terdapat beberapa saran untuk pengembangan penelitian ini di masa mendatang:

- **Pengembangan Dataset:** Disarankan untuk menambah jumlah variasi ulasan pada kategori yang memiliki kemiripan kata kunci tinggi (seperti Pertukangan dan Elektronik) agar model semakin presisi dalam membedakan produk hybrid.
- **Efisiensi Waktu:** Ke depannya, dapat dieksperimenkan penggunaan library selain Sastrawi (seperti PySastrawi atau lainnya) yang mungkin memiliki waktu eksekusi lebih cepat tanpa mengurangi kualitas akurasi.
- **Fitur Tambahan:** Mengintegrasikan model klasifikasi kategori ini dengan model Sentiment Analysis untuk memberikan wawasan lebih bagi penjual mengenai kepuasan pelanggan di tiap kategori.